

Introduction aux systèmes UNIX - Preprocessing and mapping of NGS data

École de bioinformatique
AVIESAN-IFB 2018

Denis Puthier, TAGC/Inserm,
U1090, denis.puthier@univ-amu.fr

Claire Toffano-Nioche, CNRS,
claire.toffano-nioche@u-psud.fr

Julien Seiler, IGBMC,
seilerj@igbmc.fr

Gildas le Corguillé,
lecorguille@sb-roscoff.fr

Short URL:
https://bit.ly/2-pre_processing_and_mapping_2021

Et tout le staff !!

Accès au Jupyter Lab (s'il ne tourne pas déjà)


- Navigateur : <https://jupyterhub.cluster.france-bioinformatique.fr/>
- Accès au service avec votre couple “username/password”
- Choisir l’option “Medium” et démarrer le serveur (bouton “start”)
- Choisir une session “Terminal”

The image shows a sequence of five screenshots illustrating the steps to access Jupyter Lab:

- Step 1:** A browser window showing the JupyterHub login page. The URL is <https://jupyterhub.cluster.france-bioinformatique.fr/>. There is a "Sign in" button and input fields for "Username:" and "Password:". An arrow points from this step to the next.
- Step 2:** The "Server Options" page. It shows "Select a job profile:" with a dropdown menu set to "Medium (4 cpu, 10GB RAM, 12h)". There is a large orange "Start" button. An arrow points from this step to the next.
- Step 3:** The "Launcher" page. It shows a "home" button (highlighted with a black box) and various environment icons: Python 3.7, Bash, R 3.6.3, Console, and Other. An arrow points from this step to the next.
- Step 4:** A "Terminal" icon (highlighted with a black box) showing a shell prompt. An arrow points from this step to the next.
- Step 5:** The Jupyter Lab interface. It shows a "SHUT DOWN" button (highlighted with a black box) in the bottom left corner. An arrow points from this step back to the "Terminal" icon in Step 4.

Présentation du jeu de données

- Immuno-précipitation de chromatine (ChIP-Seq).
 - Un traitement (ADN fragmenté + immunoprécipitation par Ac. anti-ESR1)
 - Un control (~ ADN fragmenté)



Research

GATA3 acts upstream of FOXA1 in mediating ESR1 binding by shaping enhancer accessibility

Vasiliki Theodorou,¹ Rory Stark,² Suraj Menon,² and Jason S. Carroll^{1,3,4}

¹Nuclear Receptor Transcription Lab, ²Bioinformatics Core, Cancer Research UK, Cambridge Research Institute, Li Ka Shing Centre, Cambridge CB2 0RE, United Kingdom; ³Department of Oncology, University of Cambridge, Cambridge CB2 0XZ, United Kingdom

Télécharger des fichiers

- On peut utiliser un **navigateur (e.g Cyberduck) pour téléverser sur le serveur**
- **Mieux**, on peut effectuer directement le téléchargement **depuis le terminal** si on dispose de l'**URL**.
 - On utilise alors la commande **wget**.

```
$ cd /shared/projects/<project> # adaptez <project>
$ cd chip-seq/fastq
$ pwd # print working directory
$ wget https://zenodo.org/record/5571592/files/siNT_ER_E2_r3_chr21.fastq.gz
$ ls
```

Decompression

- La commande **gunzip**.
 - La commande `gunzip` permet de décompresser un fichier au format *.gz. Sa syntaxe générale est la suivante:
 - `gunzip [-cfhklNqrtVv] [-S suffix] file [file [...]]`

```
$ # on décompresse le fichier *.gz.
```

```
$ gunzip siNT_ER_E2_r3_chr21.fastq.gz
```

```
$ # Regardez l'extension du fichier siNT_ER_E2_r3_chr21.fastq
```

```
$ # Que remarquez vous ?
```

```
$ ls
```

Les lectures brutes (raw reads) sont au format fastq

| | |
|---------------------|---|
| Header | @QSEQ32.249996 HWUSI-EAS1691:3:1:17036:13000#0/1 PF=0 length=36 |
| Sequence | GGGGGTCATCATCATTTGATCTGGGAAAGGCTACTG |
| + (optional header) | + |
| Quality | =.+5:<<<<>AA?0A>;A*A##### |

- La qualité est généralement au format Sanger (cf prochaine diapo).
- Exercice
 - Utilisez une des commandes vues précédemment pour visualiser le contenu du fichier fastq

Les lectures brutes (raw reads) sont au format fastq

| | |
|---------------------|---|
| Header | @QSEQ32.249996 HWUSI-EAS1691:3:1:17036:13000#0/1 PF=0 length=36 |
| Sequence | GGGGGTCATCATCATTTGATCTGGGAAAGGCTACTG |
| + (optional header) | + |
| Quality | =.+5:<<<<>AA?0A>;A*A##### |

```
$ # Vous pouvez utiliser la commande less pour visualiser le contenu du
$ # fichier.
$ # q pour quitter
$ less siNT_ER_E2_r3_chr21.fastq
```

Le score de qualité Sanger

- Une valeur de score Sanger est attribuée à chaque base séquencée
 - Basée sur p , la probabilité d'erreur (i.e. que la base soit fausse)
 - $Q_{\text{Sanger}} = -10 \cdot \log_{10}(p)$
 - $p = 0.1 \Leftrightarrow Q_{\text{Sanger}} 10$
 - $p = 0.01 \Leftrightarrow Q_{\text{Sanger}} 20$
 - $p = 0.001 \Leftrightarrow Q_{\text{Sanger}} 30$
 - ...
- Les scores sont encodés en ASCII 33
 - Objectif : compresser les données en diminuant le nombre de caractères utilisés pour encoder la qualité.
- Le score de qualité Sanger varie entre 0 et 40

Le score de qualité Sanger

- ! correspond à 0
- “ correspond à 1
- # correspond à 2
- \$ correspond à 3
- ...
- I correspond à 40


| Dec | Hex | Char | Dec | Hex | Char | Dec | Hex | Char | Dec | Hex | Char |
|-----|-----|------------------|-----|-----|-------|-----|-----|------|-----|-----|------|
| 0 | 00 | Null | 32 | 20 | Space | 64 | 40 | @ | 96 | 60 | ` |
| 1 | 01 | Start of heading | 33 | 21 | ! | 65 | 41 | A | 97 | 61 | a |
| 2 | 02 | Start of text | 34 | 22 | " | 66 | 42 | B | 98 | 62 | b |
| 3 | 03 | End of text | 35 | 23 | # | 67 | 43 | C | 99 | 63 | c |
| 4 | 04 | End of transmit | 36 | 24 | \$ | 68 | 44 | D | 100 | 64 | d |
| 5 | 05 | Enquiry | 37 | 25 | % | 69 | 45 | E | 101 | 65 | e |
| 6 | 06 | Acknowledge | 38 | 26 | & | 70 | 46 | F | 102 | 66 | f |
| 7 | 07 | Audible bell | 39 | 27 | ' | 71 | 47 | G | 103 | 67 | g |
| 8 | 08 | Backspace | 40 | 28 | (| 72 | 48 | H | 104 | 68 | h |
| 9 | 09 | Horizontal tab | 41 | 29 |) | 73 | 49 | I | 105 | 69 | i |
| 10 | 0A | Line feed | 42 | 2A | * | 74 | 4A | J | 106 | 6A | j |
| 11 | 0B | Vertical tab | 43 | 2B | + | 75 | 4B | K | 107 | 6B | k |
| 12 | 0C | Form feed | 44 | 2C | , | 76 | 4C | L | 108 | 6C | l |
| 13 | 0D | Carriage return | 45 | 2D | - | 77 | 4D | M | 109 | 6D | m |
| 14 | 0E | Shift out | 46 | 2E | . | 78 | 4E | N | 110 | 6E | n |
| 15 | 0F | Shift in | 47 | 2F | / | 79 | 4F | O | 111 | 6F | o |
| 16 | 10 | Data link escape | 48 | 30 | 0 | 80 | 50 | P | 112 | 70 | p |
| 17 | 11 | Device control 1 | 49 | 31 | 1 | 81 | 51 | Q | 113 | 71 | q |
| 18 | 12 | Device control 2 | 50 | 32 | 2 | 82 | 52 | R | 114 | 72 | r |
| 19 | 13 | Device control 3 | 51 | 33 | 3 | 83 | 53 | S | 115 | 73 | s |
| 20 | 14 | Device control 4 | 52 | 34 | 4 | 84 | 54 | T | 116 | 74 | t |
| 21 | 15 | Neg. acknowledge | 53 | 35 | 5 | 85 | 55 | U | 117 | 75 | u |
| 22 | 16 | Synchronous idle | 54 | 36 | 6 | 86 | 56 | V | 118 | 76 | v |
| 23 | 17 | End trans. block | 55 | 37 | 7 | 87 | 57 | W | 119 | 77 | w |
| 24 | 18 | Cancel | 56 | 38 | 8 | 88 | 58 | X | 120 | 78 | x |
| 25 | 19 | End of medium | 57 | 39 | 9 | 89 | 59 | Y | 121 | 79 | y |
| 26 | 1A | Substitution | 58 | 3A | : | 90 | 5A | Z | 122 | 7A | z |
| 27 | 1B | Escape | 59 | 3B | ; | 91 | 5B | [| 123 | 7B | { |
| 28 | 1C | File separator | 60 | 3C | < | 92 | 5C | \ | 124 | 7C | |
| 29 | 1D | Group separator | 61 | 3D | = | 93 | 5D |] | 125 | 7D | } |
| 30 | 1E | Record separator | 62 | 3E | > | 94 | 5E | ^ | 126 | 7E | ~ |
| 31 | 1F | Unit separator | 63 | 3F | ? | 95 | 5F | _ | 127 | 7F | □ |

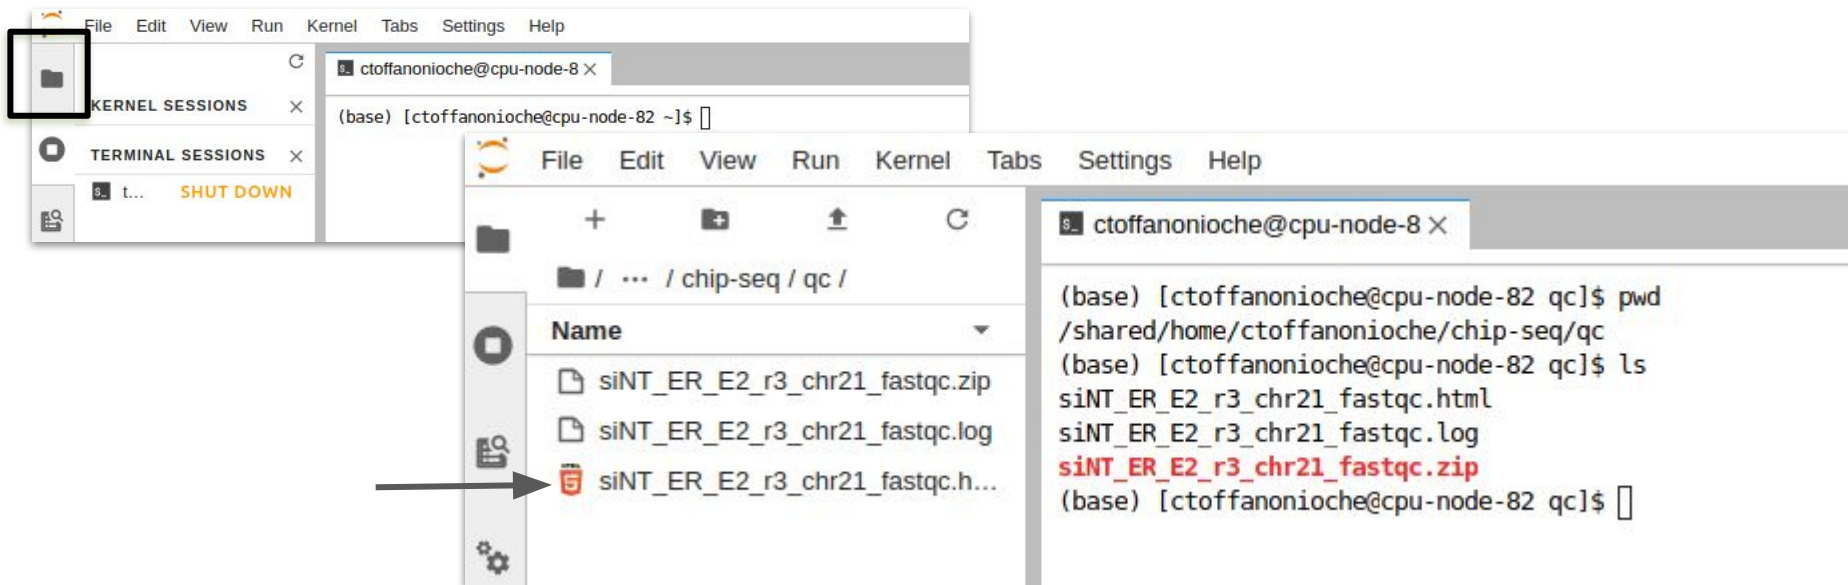
Analyser la qualité avec fastQC

- Fast Quality Control (FastQC)
 - Propose un certain nombre de diagrammes qualité pour évaluer la qualité du séquençage.
 - `fastqc [-o output dir] [--(no)extract] [-f fastq|bam|sam] fq1 fq2 ...`

```
$ cd ..                                # On remonte d'un niveau dans l'arborescence
$ mkdir qc                             # On crée un répertoire
$ ls -l ; cd qc                        # 2 instructions sur la même ligne séparées par ';'
$ module load fastqc/0.11.8           # Charge le chemin de fastqc dans l'environnement
$ fastqc -h                            # Obtenir de l'aide
$ # Lancer fastqc
$ # Ici le \ indique un retour à la ligne mais vous n'êtes pas censé le
$ # taper et aller à la ligne
$ fastqc -f fastq -o ./ ../fastq/siNT_ER_E2_r3_chr21.fastq \
    2> siNT_ER_E2_r3_chr21_fastqc.log
$ less siNT_ER_E2_r3_chr21_fastqc.log  # la sortie d'erreur de fastqc
$ ls                                   # Que voyez vous ?
```

Jupyter Lab : accès au fichier html

- Côté gauche, avec l'onglet  on se place à la racine du cluster
- Sélectionner les répertoires jusqu'au répertoire de travail
/shared/projects/<project>/chip-seq/qc
- Cliquer sur le fichier html pour l'ouvrir dans l'onglet

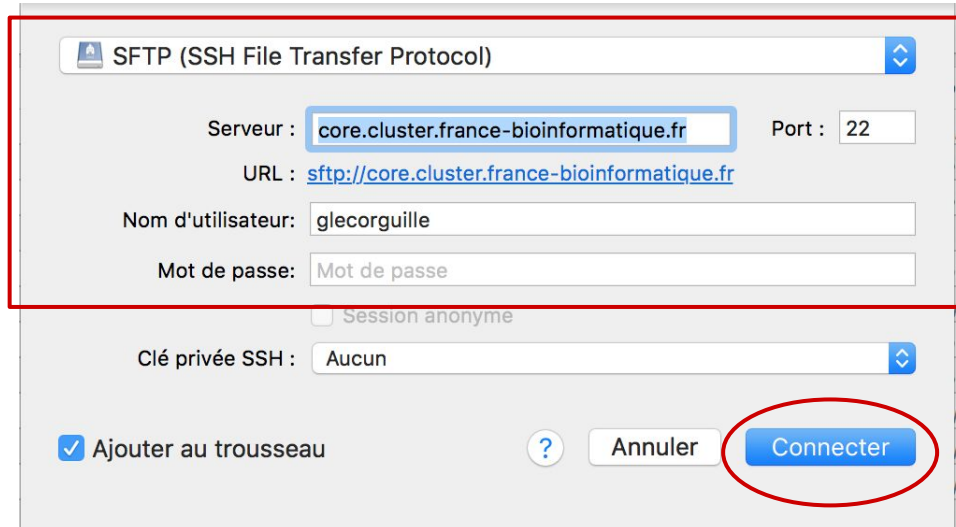
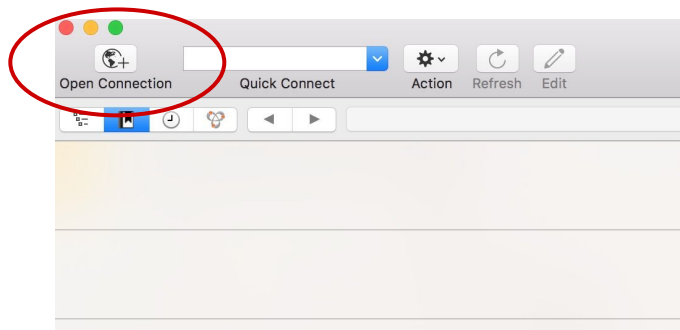
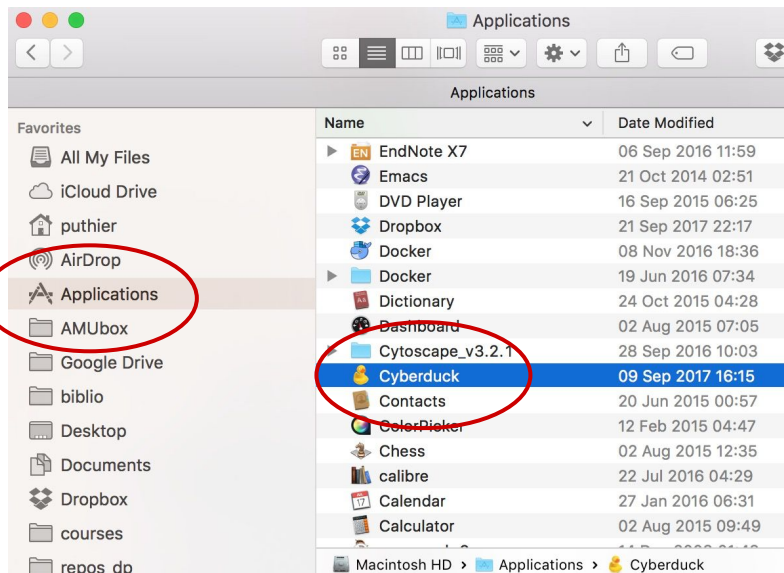


The screenshot displays the Jupyter Lab interface. On the left sidebar, the 'File Explorer' icon is highlighted with a black box. The main panel shows the file tree for the directory `/shared/projects/<project>/chip-seq/qc/`. The file `siNT_ER_E2_r3_chr21_fastqc.h...` is selected, indicated by a black arrow. The right panel shows the terminal output for the user `ctoffanonioche@cpu-node-82`. The terminal shows the current directory and the contents of the selected file.


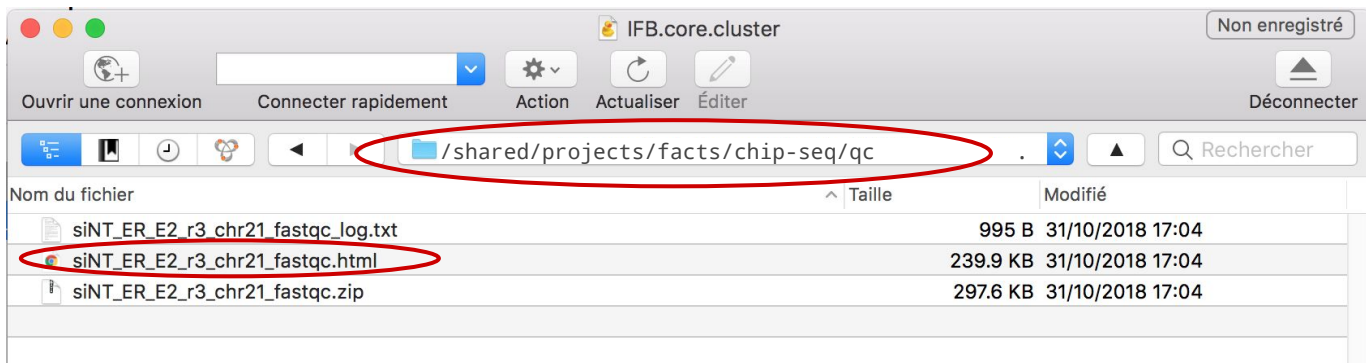
```
(base) [ctoffanonioche@cpu-node-82 ~]$  
  
File Edit View Run Kernel Tabs Settings Help  
+ + + +  
/ ... / chip-seq / qc /  
Name  
siNT_ER_E2_r3_chr21_fastqc.zip  
siNT_ER_E2_r3_chr21_fastqc.log  
siNT_ER_E2_r3_chr21_fastqc.h...
```

```
(base) [ctoffanonioche@cpu-node-82 qc]$ pwd  
/shared/home/ctoffanonioche/chip-seq/qc  
(base) [ctoffanonioche@cpu-node-82 qc]$ ls  
siNT_ER_E2_r3_chr21_fastqc.html  
siNT_ER_E2_r3_chr21_fastqc.log  
siNT_ER_E2_r3_chr21_fastqc.zip  
(base) [ctoffanonioche@cpu-node-82 qc]$
```

Télécharger les résultats avec Cyberduck (OSX)

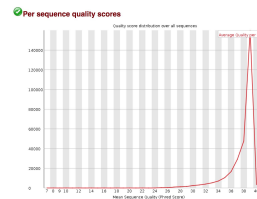

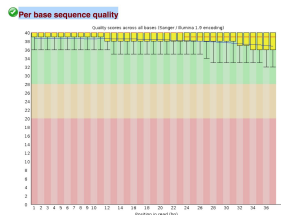


Résultats de FastQC




Résultats de FastQC

- Exploration des résultats de fastqc en interactif.
 - A quoi correspond le diagramme “**Per base sequence quality**”.
 - A quoi correspond le diagramme “**Per sequence quality score**” ?
 - A quoi correspond le diagramme “**Per base sequence content**” ?
 - A quoi correspond le diagramme “**Per sequence GC content**” ?
 - A quoi correspond le diagramme “**Per sequence N content**” ?
 - A quoi correspond le diagramme “**Sequence length distribution**” ?
 - A quoi correspond le diagramme “**Sequence duplication level**” ?
 - A quoi correspond le diagramme “**Kmer content**” ?



Rogner les reads

- Une étape de pré-processing
 - Les reads en entrée sont rognés afin d'éliminer des extrémités de mauvaises qualités.
 - En fonction de la capacité de l'outil à faire des alignements locaux ou globaux et de la qualité intrinsèque des données, cette étape peut être cruciale.
 - Risque: peu de reads alignés
- Quelques logiciels existants
 - Sickle-trim (sliding window-based trimming)
 - FASTX-Toolkit (cut a defined number of nucleotides)
 - Trimmomatic
 - Cutadapt



Principe de sickle

- Objectif:
 - **Supprimer** les extrémités de mauvaise qualité.
- Solution:
 - Parcourir le read avec un **fenêtre coulissante** de droite à gauche. Calculer la **qualité moyenne** dans chaque fenêtre
 - Si la valeur de qualité chute en dessous d'une **valeur seuil q** , déléter l'extrémité 3'.
 - Si la taille restante du read est inférieure à une **longueur seuil l** , déléter le read.

ACTCGCTCGCTGGTTAATCGATGATCGTGCAGTCGTACTCGTAGCTAGCTAGTCGTAACATAGCTAGTC





L'interface de sickle

- Sickle contient plusieurs **sous-commandes**: **pe** et **se**.

```
$ module load sickle-trim/1.33  
$ sickle -h
```

Usage: sickle <command> [options]

Command:

```
pe  paired-end sequence trimming  
se  single-end sequence trimming
```

```
--help, display this help and exit
```

```
--version, output version information and exit
```

```
$ sickle se --help # Obtenir de l'aide sur la sous-commande se.
```

Exercice (noté)

- Créez un **répertoire trimmed** au même niveau dans l'arborescence que fastq.
- Déplacez vous dans ce répertoire.
- Invoquez l'aide de sickle (se)
- Construisez une commande qui combine les options suivantes:
 - Fournissez à **sickle** le fichier d'entrée **siNT_ER_E2_r3_chr21.fastq**.
 - Qualité de type "Sanger", seuils de qualité et de longueur tous deux à 20.
 - Demandez à sickle se de produire un fichier de sortie que vous nommerez **siNT_ER_E2_r3_chr21_trim.fastq** et qui devra être créé dans le dossier trimmed.
 - Rediriger la sortie standard dans un fichier que vous nommerez **siNT_ER_E2_r3_chr21_sicke_log.txt** placé dans le dossier trimmed.
- Comptez le nombre de lignes présentes dans les fichiers fastq avant et après utilisation de sickle (commande wc -l).
- Lisez le contenu du fichier log. Obtenez-vous le même résultat ?

Corrigé

```
$ cd ..                # On remonte d'un niveau dans l'arborescence
$ mkdir trimmed        # On crée un répertoire
$ cd trimmed           # On se déplace dans ce répertoire
$ # On lance sickle
$ # Ici le \ indique un retour à la ligne mais vous n'êtes pas censé le
$ # taper et aller à la ligne
$ # 2> redirige la sortie d'erreur
$ sickle se -f ../fastq/siNT_ER_E2_r3_chr21.fastq \
    -t sanger -o siNT_ER_E2_r3_chr21_trim.fastq \
    > siNT_ER_E2_r3_chr21_sickle.log
$ # le nombre de lignes présentes dans les fichiers fastq
$ wc -l ../fastq/siNT_ER_E2_r3_chr21.fastq    # Données brutes
$ wc -l siNT_ER_E2_r3_chr21_trim.fastq        # Données nettoyées
```




Mapping

Aligner les reads

- Objectif
 - Trouver la région du génome qui a produit les read.
 - Trouver dans le génome le mot correspondant au read


Ref. Genome



Reads

- Une position dans le génome
- Plusieurs positions (éléments répétés, région de basse complexité)

L'approche de bowtie: *seed and extend*

- Une extrémité du read est interrogée (la graine) 
- On cherche ses régions correspondantes sur le génome (à l'aide d'un index créé initialement) avec ou sans mismatch.
- On teste si le reste du read s'aligne avec la séquence



Aligner les reads

- Pour l'alignement nous utiliserons **Bowtie 2**.
- Bowtie 2 nécessite de préparer un **index**.
 - Cet index permettra une recherche optimisée de la position d'un mot w dans le génome.
 - Des index pour les génomes utilisés classiquement sont disponibles sur le [site de bowtie 2](#).
 - Ici nous voulons restreindre le génome au chromosome 21, nous devons donc construire cet index.

```
# Créez un répertoire pour y stocker l'index dans chip-seq/  
$ cd ..  
$ mkdir index  
$ cd index
```

Création de l'index

- Ne faire qu'une seule fois par génome d'intérêt et version majeure !
- Allez sur le site de l'UCSC à l'adresse suivante
 - <https://genome.ucsc.edu/>
- Cliquez sur Downloads > Genome Data > human > hg38 > Data set by chromosome.
- Recherchez le fichier **chr21.fa.gz**
- Cliquez bouton droit "Copy link address"

```
$ # Téléchargez l'index avec wget
$ wget http://hgdownload.soe.ucsc.edu/goldenPath/hg38/chromosomes/chr21.fa.gz
$ # décompression
$ gunzip chr21.fa.gz
$ module load bowtie2/2.3.4.3 samtools/1.9      # ici on charge 2 outils à la fois
$ # Construction de l'index
$ bowtie2-build chr21.fa chr21_hg38
```


Alignement

- On crée un répertoire de travail et on se positionne dans celui-ci
- On lancera l'alignement dans depuis le dossier 'bam'.

```
# Create a directory
```

```
$ mkdir ../bam
```

```
# Change directory
```

```
$ cd ../bam
```



Alignement (do not run!)

- L'alignement est réalisé avec **bowtie2**, qui produit un flux de texte au format **sam** (texte), **volumineux**.

```
# Perform alignment
```

```
$ bowtie2 -p 4 -x ../index/chr21_hg38 -U ../trimmed/siNT_ER_E2_r3_chr21_trim.fastq \  
2> siNT_ER_E2_r3_chr21_trim_bowtie2.log
```

Alignement (do not run!)

- L'alignement est réalisé avec **bowtie2**, qui produit un flux de texte au format **sam** (texte), **volumineux**.
- Ce flux de texte peut être redirigé (|) vers '**samtools view -hbS**' (-h: header, -b output is BAM, -S: input is SAM) pour produire une version compressée (format **bam**).

```
# -bS (sortie en bam, entrée en sam)
```

```
$ bowtie2 -p 4 -x ../index/chr21_hg38 -U ../trimmed/siNT_ER_E2_r3_chr21_trim.fastq \  
2> siNT_ER_E2_r3_chr21_trim_bowtie2.log | samtools view -hbS
```

Alignement (do not run!)

- L'alignement est réalisé avec **bowtie2**, qui produit un flux de texte au format **sam** (texte), **volumineux**.
- Ce flux de texte peut être redirigé (|) vers '**samtools view -hbS**' (-h: header, -b output is BAM, -S: input is SAM) pour produire une version compressée (format **bam**).
- On sélectionne le sous-ensemble des reads pour lequel la mapping quality (-q: quality) est au moins égale à 30.

```
# -q 30 (quality 30)
```

```
$ bowtie2 -p 4 -x ../index/chr21_hg38 -U ../trimmed/siNT_ER_E2_r3_chr21_trim.fastq \  
2> siNT_ER_E2_r3_chr21_trim_bowtie2.log | samtools view -hbS -q 30
```

Alignement (do not run!)

- L'alignement est réalisé avec **bowtie2**, qui produit un flux de texte au format **sam** (texte), **volumineux**.
- Ce flux de texte peut être redirigé (|) vers '**samtools view -hbS**' (-h: header, -b output is BAM, -S: input is SAM) pour produire une version compressée (format **bam**).
- On sélectionne le sous-ensemble des reads pour lequel la mapping quality (-q: quality) est au moins égale à 30.
- Le flux de texte est redirigé (|) vers '**samtools sort**' (trie par coordonnées génomiques).

Trie l'alignement

```
$ bowtie2 -p 4 -x ../index/chr21_hg38 -U ../trimmed/siNT_ER_E2_r3_chr21_trim.fastq \
2> siNT_ER_E2_r3_chr21_trim_bowtie2.log | samtools view -hbS -q 30 | samtools sort
```

Alignement (now you can run)

- L'alignement est réalisé avec **bowtie2**, qui produit un flux de texte au format **sam** (texte), **volumineux**.
- Ce flux de texte peut être redirigé (|) vers '**samtools view -hbS**' (-h: header, -b output is BAM, -S: input is SAM) pour produire une version compressée (format **bam**).
- On sélectionne le sous-ensemble des reads pour lequel la mapping quality (-q: quality) est au moins égale à 30.
- Le flux de texte est redirigé (|) vers '**samtools sort**' (trie par coordonnées génomiques).
- Le flux de texte est redirigé dans un fichier ('>')

'>' est un opérateur de redirection

```
$ bowtie2 -p 4 -x ../index/chr21_hg38 -U ../trimmed/siNT_ER_E2_r3_chr21_trim.fastq \
2> siNT_ER_E2_r3_chr21_trim_bowtie2.log | samtools view -hbS -q 30 | samtools sort \
> siNT_ER_E2_r3_chr21_trim.bam
```

Alignement

- L'alignement est réalisé avec **bowtie2**, qui produit un flux de texte au format **sam** (texte), **volumineux**.
- Ce flux de texte peut être redirigé (|) vers '**samtools view -hbS**' (-h: header, -b output is BAM, -S: input is SAM) pour produire une version compressée (format **bam**).
- On sélectionne le sous-ensemble des reads pour lequel la mapping quality (-q: quality) est au moins égale à 30.
- Le flux de texte est redirigé (|) vers '**samtools sort**' (trie par coordonnées génomiques).
- Le flux de texte est redirigé dans un fichier ('>')
- Le fichier est indexé pour optimiser la recherche de position dans le BAM (création d'un fichier *.bai).

Indexation de l'alignement

```
$ bowtie2 -p 4 -x ../index/chr21_hg38 -U ../trimmed/siNT_ER_E2_r3_chr21_trim.fastq \
2> siNT_ER_E2_r3_chr21_trim_bowtie2.log | samtools view -hbS -q 30 | samtools sort \
> siNT_ER_E2_r3_chr21_trim.bam
$ samtools index siNT_ER_E2_r3_chr21_trim.bam
$ ls
```

Fichier bam

- SAM: 'Sequence Alignment/Map'
- BAM: binary/compressed version of SAM
- Stocke les informations liées à l'alignement
 - Coordonnées du read aligné
 - Mapping quality
 - CIGAR String
 - Bitwise FLAG
 - read paired, read mapped in proper pair, read unmapped, ...
 - ...

Sequence Alignment/Map Format Specification

The SAM/BAM Format Specification Working Group

2 Sep 2016

Visualiser le contenu du fichier bam

- Le fichier bam est compressé.
- On peut voir son contenu avec la commande `samtools`.

```
# Visualiser le contenu du fichier bam
# On utilise l'argument -h pour visualiser aussi le 'header'.
# On renvoie le flux de texte dans less.
# On ajoute le paramètre -S pour tronquer les lignes qui excèdent
# la largeur de l'écran
$ samtools view -h siNT_ER_E2_r3_chr21_trim.bam | less -S
```

Bitwise flag

- De nombreuses informations sont stockées dans la colonne 2 du fichier SAM/BAM
 - read pairs
 - reads mapped in proper pairs
 - reads unmapped
 - mates unmapped
 - reads reverse strand
 - mates reverse strand
 - first in pair
 - second in pair
 - not primary alignment
 - ...

Bitwise flag

- 000000000001 $\rightarrow 2^0 = 1$ (read paired)
- 000000000010 $\rightarrow 2^1 = 2$ (read mapped in proper pair)
- 000000000100 $\rightarrow 2^2 = 4$ (read unmapped)
- 000000001000 $\rightarrow 2^3 = 8$ (mate unmapped) ...
- 000000010000 $\rightarrow 2^4 = 16$ (read reverse strand)
- 000000001001 $\rightarrow 2^0 + 2^3 = 9 \rightarrow$ (read paired, mate unmapped)
- 000000001101 $\rightarrow 2^0 + 2^2 + 2^3 = 13$...
- ...

Voir [Explained SAM flags](#)

The extended CIGAR string


- Quelques exemples de drapeaux (flag)
 - M match ou mismatch...
 - I Insertion par rapport à la référence
 - D Délétion par rapport à la référence
 - N Espace dans l'alignement (Gap)
- <http://samtools.sourceforge.net/SAM1.pdf>

ATTCAGATGCAGTA
ATTCA--TGCAGTA

5M2D7M



Pourquoi filtrer sur la qualité ?

- Sommes-nous plus confiants
 - dans l'alignement du read **1** ?
 - dans l'alignement read **2** ?



Pourquoi filtrer sur la qualité ?

- Sommes-nous plus confiants
 - dans l'alignement **1** ?
 - Si la moyenne de qualité des nucléotides séquencés dans le read est 40
 - dans l'alignement **1'** ?
 - Si la moyenne de qualité des nucléotides séquencés dans le read est 10 ?



Filtering for Mapping Quality (MAPQ)

- Mapping quality is a score that integrates both the quality of the read itself and the number of positions it maps
- Mapping quality score is computed from the probability that alignment is wrong:
 - takes mappability and sequence quality into account
 - $-10 \cdot \log_{10}(\text{Prob}(\text{alignment is wrong}))$
 - $p=0.01 \rightarrow \text{MAPQ: } 20$
 - $p=0.001 \rightarrow \text{MAPQ: } 30$
 - $p=0.0001 \rightarrow \text{MAPQ: } 40$
 - ...



Merci pour votre attention.

**Remerciements à toute l'équipe
pédagogique et technique pour le
support**